

• 论 著 •

基于黎曼空间滤波与域适应的跨时间运动想象-脑电解码研究

潘林聪^{1,2}, 孙新维^{1,2}, 王坤^{1,3}, 曹愉培¹, 许敏鹏^{1,3}, 明东^{1,3}

1. 天津大学 医学工程与转化医学研究院 (天津 300072)

2. 天津大学 精密仪器与光电子工程学院 (天津 300072)

3. 脑机交互与人机共融海河实验室 (天津 300392)

【摘要】 运动想象(MI)是一种无需实际运动即可通过脑电图(EEG)识别的心理过程,它在脑-机接口(BCI)技术领域具有重要的研究价值和应用前景。然而,MI-EEG信号的非平稳性和低信噪比使得其分类成为一项挑战。本研究提出了一种基于黎曼空间滤波与域适应(RSFDA)的方法,旨在提高MI-BCI跨时间分类任务的准确性与效率。该方法通过多模块协同的方式,有效解决了源域与目标域数据分布不一致的问题,提升了跨时间MI-EEG分类任务的泛化能力。本文在三个公开数据集上对比了RSFDA与八种现有竞争方法的分类准确率和训练时间成本。结果显示,RSFDA的平均分类准确率为79.37%,对比分类效果最好的深度学习方法Tensor-CSPNet的76.46%提高了2.91% ($P < 0.01$)。此外,RSFDA还具有较低的计算成本,平均训练时间约为3 min,对比Tensor-CSPNet的25 min缩短了22 min。因此,RSFDA方法在跨时间的MI-EEG分类任务中表现出色,兼具准确性和高效性,但它在复杂迁移场景中的表现仍需进一步研究和验证。

【关键词】 脑-机接口; 脑电信号; 运动想象; 机器学习; 跨时间

Cross-session motor imagery-electroencephalography decoding with Riemannian spatial filtering and domain adaptation

PAN Lincong^{1,2}, SUN Xinwei^{1,2}, WANG Kun^{1,3}, CAO Yupei¹, XU Minpeng^{1,3}, MING Dong^{1,3}

1. Academy of Medical Engineering and Translational Medicine, Tianjin University, Tianjin 300072, P. R. China

2. School of Precision Instruments and Opto-Electronic Engineering, Tianjin University, Tianjin 300072, P. R. China

3. Haihe Laboratory of Brain-computer Interaction and Human-machine Integration, Tianjin 300392, P. R. China

Corresponding author: XU Minpeng, Email: minpeng.xu@tju.edu.cn

【Abstract】 Motor imagery (MI) is a mental process that can be recognized by electroencephalography (EEG) without actual movement. It has significant research value and application potential in the field of brain-computer interface (BCI) technology. To address the challenges posed by the non-stationary nature and low signal-to-noise ratio of MI-EEG signals, this study proposed a Riemannian spatial filtering and domain adaptation (RSFDA) method for improving the accuracy and efficiency of cross-session MI-BCI classification tasks. The approach addressed the issue of inconsistent data distribution between source and target domains through a multi-module collaborative framework, which enhanced the generalization capability of cross-session MI-EEG classification models. Comparative experiments were conducted on three public datasets to evaluate RSFDA against eight existing methods in terms of classification accuracy and computational efficiency. The experimental results demonstrated that RSFDA achieved an average classification accuracy of 79.37%, outperforming the state-of-the-art deep learning method Tensor-CSPNet (76.46%) by 2.91% ($P < 0.01$). Furthermore, the proposed method showed significantly lower computational costs, requiring only approximately 3 minutes of average training time compared to Tensor-CSPNet's 25 minutes, representing a reduction of 22 minutes. These findings indicate that the RSFDA method demonstrates superior performance in cross-session MI-EEG classification tasks by effectively balancing accuracy and efficiency. However, its applicability in complex transfer learning scenarios remains to be further investigated.

DOI: 10.7507/1001-5515.202411035

基金项目: 国家自然科学基金项目 (62122059, 62206198)

通信作者: 许敏鹏, Email: minpeng.xu@tju.edu.cn

*第二十七届中国科协年会学术论文

【Key words】 Brain-computer interface; Electroencephalography; Motor imagery; Machine learning; Cross-session

0 引言

脑-机接口 (brain-computer interface, BCI) 是一种直接连接大脑与外部设备的通信系统, 通过解码神经信号实现人机交互^[1]。运动想象脑-机接口 (motor imagery BCI, MI-BCI) 是 BCI 技术的一个重要分支, 允许用户仅通过想象肢体动作来控制设备, 而无需实际执行^[2]。MI-BCI 在康复医疗^[3]、辅助设备控制^[4-5] 和虚拟现实^[6-7] 等领域展现出广泛的应用前景, 成为近年来的研究热点。

MI-BCI 的信号采集方式包括脑电图 (electroencephalography, EEG)、功能性磁共振和近红外光谱等^[8]。其中, EEG 凭借高时间分辨率、便携性和低成本, 成为 MI-BCI 研究中最常见的信号类型之一^[9]。然而, EEG 信号的质量易受外界因素和个体差异的影响, 尤其在跨时间场景下, 电极位置的微小变化、皮肤电阻的波动、环境噪声及用户状态的变化都会引起 EEG 信号的显著差异, 增加了 MI 解码的难度^[10]。为应对这一挑战, 传统的 MI-BCI 系统通常需要在每次使用前进行长时间的训练, 以更新分类模型^[10]。这不仅增加了 MI-BCI 系统的使用成本, 也降低了用户体验, 限制了其实用性。

针对 EEG 信号的变异性问题, 研究人员提出了多种信号处理方法^[11-15], 其中黎曼几何方法凭借其独特的数学结构和几何特性, 展现出显著优势。例如, 基于黎曼几何的最小平均距离 (minimum distance to mean, MDM)^[16] 和切空间映射 (tangent space mapping, TSM) 方法^[17], 通过在流形空间中处理数据, 能够更好地保留信号的几何属性, 提供更为稳健和精确的特征表示, 减少噪声干扰。黎曼空间对齐 (Riemannian alignment, RA)^[18-19] 和流形嵌入式知识迁移 (manifold embedded knowledge transfer, MEKT)^[20] 方法, 通过在不同域之间对齐数据分布, 可有效地减少域间差异, 提升模型的迁移能力和泛化性。此外, EEGNet^[21]、Tensor-CSPNet^[22] 和 LMDA-Net^[23] 等深度学习方法也被引入 MI-EEG 分类。这些方法通过神经网络的强大学习能力, 能够自动提取复杂的隐含特征, 在处理高维和非线性数据时表现出色, 具有较强的分类能力。然而, 这些方法在处理跨时间数据时仍存在诸多局限, 如计算复杂度高、对大量训练数据的需求以及模型的泛化能力有限等, 导致其实际应用效果仍不理想。

为此, 本文提出了基于黎曼空间滤波与域适应 (Riemannian spatial filtering and domain adaptation, RSFDA) 方法, 以应对 EEG 信号跨时间变异性问题。RSFDA 结合了新提出的黎曼空间滤波 (Riemannian spatial filtering, RSF)^[24]、流形嵌入式特征对齐 (manifold embedded feature alignment, MEFA) 以及基于时频特征融合的 Stacking 集成学习 (stacking ensemble learning with time-frequency feature fusion, TF-Stacking) 等技术, 能够在不依赖大量重新训练的情况下, 显著提高跨时间 MI-EEG 信号的分类性能。

1 方法

1.1 基于黎曼空间滤波的域适应方法

RSFDA 方法旨在解决 MI-EEG 信号分类中的跨时间变异性问题。图 1 展示了使用 RSFDA 方法训练一个基础模型的流程。首先, 计算 EEG 信号的协方差矩阵并输入到 RSF 中。RSF 不仅能够对 EEG 信号进行空间滤波, 还可以降低数据维度, 从中提取出具有代表性的关键信息。相比于传统的欧几里得空间方法, 黎曼几何在应对 EEG 信号中的噪声干扰及高维数据处理时表现更为优越, 确保了空间滤波的有效性^[24]。其次, 为了应对跨时间场景下信号分布的差异性, RSFDA 引入了 RA 方法。通过对不同时间段的样本进行预对齐, RA 方法能够有效减少由于电极位置变化、皮肤电阻波动等因素引起的 EEG 信号变异性, 从而为后续的分类模型提供更加一致的输入数据。然后, RSFDA 提取各时间段 EEG 样本的黎曼切空间 (tangent space, TS) 特征。这些特征能够有效地表示黎曼空间中样本的几何结构, 对比单一的距离特征具有更好的可分性^[17]。在此基础上, RSFDA 通过 MEFA 方法进一步对跨时间段的特征进行对齐, 确保不同时间段 EEG 信号在特征空间内分布的一致性, 从而进一步提高分类器的泛化能力。最后, 使用 LDA 分类器对提取的特征进行分类。

为了进一步提高 MI-EEG 信号分类的准确性和稳定性, RSFDA 还结合了 TF-Stacking 方法。如图 2 所示, 该方法通过多种时间窗和频带的组合提取不同的时频特征, 在每个组合上分别训练单个基模型。随后, 所有基模型的输出被整合为新的输入, 以训练一个元分类器。因此, TF-Stacking 能够更全面地利用 EEG 信号中的时频信息。




图1 RSFDA 基模型训练流程

Fig.1 Training process of the RSFDA base model

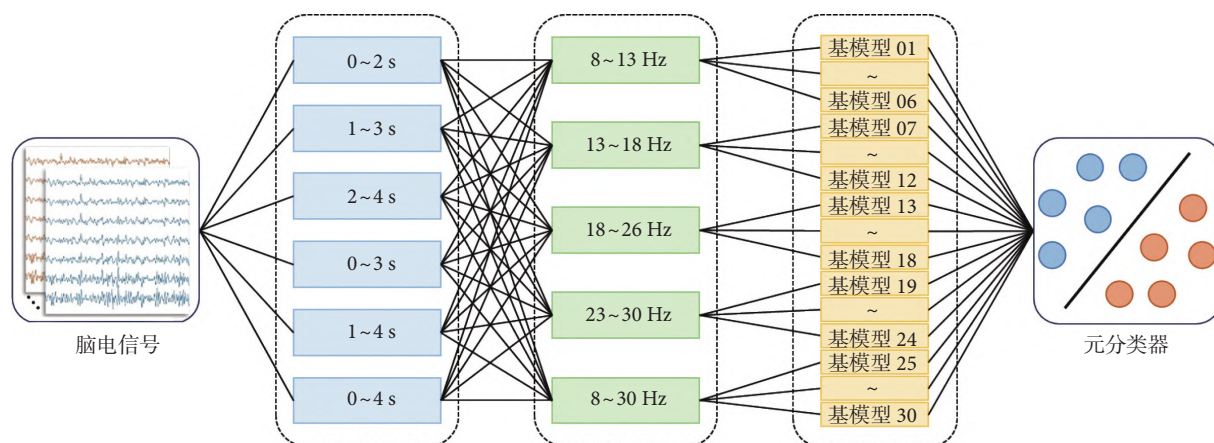


图2 TF-Stacking 的计算流程

Fig.2 Workflow of TF-Stacking

1.2 黎曼空间滤波器

在多通道脑电信号处理研究中, 样本协方差矩阵 (sample covariance matrix, SCM) 是用来捕捉脑电信号空间分布特征的重要统计工具。用 $\mathbf{X}_i \in \mathbb{R}^{n_c \times n_t}$ 表示第 i 个样本, 其中 n_c 为通道数, n_t 为时间点数。归一化的 SCM 定义为:

$$\mathbf{C}_i = \frac{\mathbf{X}_i \mathbf{X}_i^T}{\text{tr}(\mathbf{X}_i \mathbf{X}_i^T)} \in \mathbb{R}^{n_c \times n_c} \quad (1)$$

其中, $\text{tr}(\cdot)$ 表示矩阵的迹。由于 SCM 具有严格的正特征值, 因此可用对称正定 (symmetric positive definite, SPD) 矩阵来表征。根据仿射不变黎曼度量, SPD 流形中两个样本之间的测地线距离定义为:

$$\delta_R(\mathbf{C}_1, \mathbf{C}_2) = \|\log(\mathbf{C}_1^{-1} \mathbf{C}_2)\|_F = \left[\sum_{i=1}^n \log^2 \lambda_i \right]^{\frac{1}{2}} \quad (2)$$

其中, $\log(\cdot)$ 表示矩阵的对数运算, $\|\cdot\|_F$ 表示矩阵的 Frobenius 范数, $\lambda_i (i=1, \dots, n_c)$ 是 $\mathbf{C}_1^{-1} \mathbf{C}_2$ 的实特征值。黎曼几何均值定义为:

$$\bar{\mathbf{C}} = \underset{\mathbf{C} \in \text{SPD}}{\text{argmin}} \sum_{i=1}^n \delta_R^2(\mathbf{C}, \mathbf{C}_i) \quad (3)$$

RSF 旨在黎曼空间中最大化两类样本几何均值之间的测地线距离, 同时减少信号的通道数, 即:

$$\mathbf{W} = \underset{\mathbf{W}}{\text{argmax}} \delta_R^2(\mathbf{W}^T \bar{\mathbf{C}}_1 \mathbf{W}, \mathbf{W}^T \bar{\mathbf{C}}_2 \mathbf{W}), n_d < n_c \quad (4)$$

其中, $\bar{\mathbf{C}}_1$ 和 $\bar{\mathbf{C}}_2$ 分别表示两类样本的黎曼几何均值, $\mathbf{W} \in \mathbb{R}^{n_c \times n_d}$ 是将信号投影到低维空间的变换矩阵。由于式 (4) 没有闭式解, 因此采用数值优化方法进行计算。经过 RSF 滤波后的信号可表示为 $\mathbf{W}^T \mathbf{X} \in \mathbb{R}^{n_d \times n_t}$, 相应的 SCM 为 $\mathbf{W}^T \mathbf{C} \mathbf{W} \in \mathbb{R}^{n_d \times n_d}$ 。

1.3 黎曼空间预对齐

RA 的核心思想是通过在黎曼空间中使用参考

矩阵进行白化处理,以提高不同源数据分布的一致性。在本文中,使用同一源的所有样本的黎曼几何均值作为参考矩阵,对该源的所有样本进行 RA 处理。RA 处理过程如下:

$$\hat{C}_i = \bar{C}^{-1/2} C_i \bar{C}^{-1/2} \quad (5)$$

其中, \bar{C} 表示同一源所有样本的黎曼几何均值。

1.4 切空间特征提取

TSM 将所有样本点映射到黎曼几何均值点的切平面上,然后取投影点矩阵的上三角元素构成特征向量:

$$\mathbf{z}_i = \text{upper}(\bar{C}^{1/2} \log(\bar{C}^{-1/2} C_i \bar{C}^{-1/2}) \bar{C}^{1/2}) \quad (6)$$

其中, $\text{upper}(\cdot)$ 表示取 SPD 矩阵的上三角元素,然后展平为向量 $\mathbf{z}_i \in \mathbb{R}^{1 \times n_d(n_d+1)/2}$, n_d 为矩阵 C_i 的维度。

1.5 流形嵌入式特征对齐

MEFA 是在 MEKT 方法的基础上进行改进的新方法。与 MEKT 对比, MEFA 主要面向有监督的迁移学习场景,即 MEFA 的计算需要目标域部分样本的标签信息。MEFA 的目标函数如下:

$$\begin{aligned} \min_{\mathbf{A}, \mathbf{B}} & \alpha_S \text{tr}(\mathbf{A}^T \mathbf{S}_w \mathbf{A}) + \alpha_T \text{tr}(\mathbf{B}^T \mathbf{T}_w \mathbf{B}) + \beta \text{tr}(\mathbf{B}^T \mathbf{X}_T \mathbf{L} \mathbf{X}_T^T \mathbf{B}) + \\ & \|\mathbf{N}_S^T \mathbf{X}_S^T \mathbf{A} - \mathbf{N}_T^T \mathbf{X}_T^T \mathbf{B}\|_F^2 + \rho (\|\mathbf{B} - \mathbf{A}\|_F^2 + \|\mathbf{B}\|_F^2) \\ \text{s.t.} & \mathbf{B}^T \mathbf{X}_T \mathbf{H} \mathbf{X}_T^T \mathbf{B} = \mathbf{I}, \mathbf{A}^T \mathbf{S}_b \mathbf{A} = \mathbf{I}, \mathbf{B}^T \mathbf{T}_b \mathbf{B} = \mathbf{I} \end{aligned} \quad (7)$$

其中, $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n_d \times n_d}$ 是待求的投影矩阵; \mathbf{S}_w 、 \mathbf{T}_w 分别是源域与目标域的内类散度矩阵, \mathbf{S}_b 、 \mathbf{T}_b 分别是源域与目标域的外类散度矩阵; \mathbf{L} 是归一化的图拉普拉斯矩阵, \mathbf{H} 是居中矩阵; $\mathbf{N}_S = \mathbf{Y}_S/n_S$ 、 $\mathbf{N}_T = \mathbf{Y}_T/n_T$ 是两个中间变量, \mathbf{Y}_S 、 \mathbf{Y}_T 分别是源域样本标签和目标域部分已知样本标签的独热编码矩阵, n_S 、 n_T 为相应的源域与目标域样本数量; α_S 、 α_T 、 β 、 ρ 是平衡各部分的超参数,在本文中的设置与原文一致,它们的值分别为: 0.01, 0.01, 0.1 和 20^[20]。设 $\mathbf{W} = [\mathbf{A}; \mathbf{B}]$, 式 (7) 的拉格朗日函数可表示为:

$$J = \text{tr} \left(\frac{\mathbf{W}^T (\alpha_S \mathbf{P}_S + \alpha_T \mathbf{P}_T + \beta \mathbf{L} + \rho \mathbf{U} + \mathbf{R}) \mathbf{W}}{\eta (\mathbf{I} - \mathbf{W}^T \mathbf{V} \mathbf{W})} \right) \quad (8)$$

其中,

$$\mathbf{P}_S = \begin{bmatrix} \mathbf{S}_w & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}, \mathbf{P}_T = \begin{bmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{T}_w \end{bmatrix} \quad (9)$$

$$\mathbf{L} = \begin{bmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{X}_T \mathbf{L} \mathbf{X}_T^T \end{bmatrix}, \mathbf{U} = \begin{bmatrix} \mathbf{I} & -\mathbf{I} \\ -\mathbf{I} & 2\mathbf{I} \end{bmatrix} \quad (10)$$

$$\mathbf{R} = \begin{bmatrix} \mathbf{X}_S \mathbf{N}_S \mathbf{N}_S^T \mathbf{X}_S^T & -\mathbf{X}_S \mathbf{N}_S \mathbf{N}_T^T \mathbf{X}_T^T \\ -\mathbf{X}_T \mathbf{N}_T \mathbf{N}_S^T \mathbf{X}_S^T & \mathbf{X}_T \mathbf{N}_T \mathbf{N}_T^T \mathbf{X}_T^T \end{bmatrix} \quad (11)$$

$$\mathbf{V} = \begin{bmatrix} \mathbf{S}_b & \mathbf{0} \\ \mathbf{0} & (\mathbf{X}_T \mathbf{H} \mathbf{X}_T^T + \mathbf{T}_b)/2 \end{bmatrix} \quad (12)$$

极值点在导数 $\nabla_{\mathbf{W}} J = 0$ 时取得, 即:

$$(\alpha_S \mathbf{P}_S + \alpha_T \mathbf{P}_T + \beta \mathbf{L} + \rho \mathbf{U} + \mathbf{R}) \mathbf{W} = \eta \mathbf{V} \mathbf{W} \quad (13)$$

通过广义特征值分解, 易得 \mathbf{W} 的解为矩阵 $\mathbf{V}^{-1}(\alpha_S \mathbf{P}_S + \alpha_T \mathbf{P}_T + \beta \mathbf{L} + \rho \mathbf{U} + \mathbf{R})$ 的特征向量。

与 MEKT 不同的另一点是, MEFA 会在进行特征转换前使用额外的特征选择方法对 TSM 提取的特征进行初步筛选。本文中使用基于互信息的特征选择^[25]方法首先将特征维度降低到 30, 再通过矩阵变换 $\mathbf{A}^T \mathbf{z}_S, \mathbf{B}^T \mathbf{z}_T \in \mathbb{R}^{1 \times n_d'}$ 分别将源域特征 \mathbf{z}_S 与目标域特征 \mathbf{z}_T 的维度降低到 $n_d' = 10$ 。

2 实验验证

2.1 实验数据

本文在三个公开的跨时间 MI-EEG 数据集上验证了 RSFDA 与其他竞争方法的有效性。

数据集 1: Pan2023^[10]。该数据集包含 14 名健康被试在两个不同时间段的 MI-EEG 数据。每个时间段包含 60 个左手和 60 个右手 MI 样本。样本通道数为 28, 时间长度为 4 s。

数据集 2: BNCI001-2014^[26]。该数据集包含 9 名健康被试在两个不同时间段的四类 MI-EEG 数据, 本文只使用其中左、右手两类 MI 任务的数据。每个时间段包含 72 个左手和 72 个右手 MI 样本。样本通道数为 22, 时间长度为 4 s。

数据集 3: BNCI001-2015^[27]。该数据集包含 12 名健康被试在两个不同时间段的 MI-EEG 数据 (其中 4 名被试有三个不同时间段的数据, 仅保留前两个时间段的数据)。每个时间段包含 100 个右手和 100 个双脚 MI 样本。样本通道数为 13, 时间长度为 5 s。

2.2 实验方法

为了模拟实际的跨时间分类场景, 每名被试第一个时间段的所有样本作为源域训练集, 第二个时间段的前 20% 样本作为目标域训练集, 第二个时间段的后续 80% 样本作为固定的测试集。预处理阶段, 对所有数据进行 8 ~ 30 Hz 的带通滤波 (Tensor-CSPNet 除外), 并保留前 4 s 的数据用于后续处理。

2.2.1 对比实验 为了验证所提出 RSFDA 方法的有效性, 将其与文献中八种常见或最新的 MI-EEG 解码方法进行了对比实验: ① EA-CSP^[28]: 使用欧



表 1 各对比方法的平均分类准确率 (%)

Tab.1 Average classification accuracy (%) of comparative methods

方法	数据集1	数据集2	数据集3	全部数据
EA-CSP	65.10 ± 12.28	78.54 ± 15.73	72.29 ± 16.85	71.02 ± 15.42
RA-CSP	64.88 ± 10.48	78.93 ± 15.59	72.66 ± 17.18	71.16 ± 15.09
TSM	69.57 ± 10.98	78.54 ± 11.51	82.34 ± 11.70	76.26 ± 12.43
MEKT	70.54 ± 10.48	77.30 ± 15.46	81.56 ± 13.78	76.06 ± 13.54
RAVE	68.08 ± 10.78	83.33 ± 12.44	81.41 ± 11.96	76.57 ± 13.31
EEGNet	56.25 ± 12.41	69.73 ± 21.03	75.78 ± 17.33	66.41 ± 18.34
LMDA-Net	57.59 ± 11.67	75.86 ± 16.77	73.91 ± 18.18	67.88 ± 17.28
Tensor-CSPNet	69.79 ± 11.68	82.18 ± 11.90	79.95 ± 13.71	76.46 ± 13.32
RSFDA	72.10 ± 10.97	83.24 ± 13.83	84.95 ± 12.56	79.37 ± 13.37

注：每个数据集上的最佳结果以粗体标记

式对齐 (Euclidean alignment, EA) 进行样本预对齐, 共空间模式 (common spatial pattern, CSP) 特征提取, 线性判别分析 (linear discriminant analysis, LDA) 分类。② RA-CSP^[10, 18]: 使用 RA 样本预对齐, CSP 特征提取, LDA 分类。③ TSM^[17]: 使用 RA 样本预对齐, TSM 特征提取, LDA 分类。④ MEKT^[20]: 使用 RA 样本预对齐, TSM 特征提取, MEKT 特征对齐, LDA 分类。⑤ RAVE^[10]: 使用 RA 样本预对齐, MDM 特征提取, LDA 分类, 自适应提升 (adaptive boosting, AdaBoost) 方法进行基础模型的增强, 最后使用 Stacking 方法集成多个时频带的分类结果进行最终决策。⑥ EEGNet^[21]: 使用 RA 样本预对齐, EEGNet 分类。本文的 EEGNet 沿用了最新版 EEGNetv4, 时间和空间滤波器的数量分别为 8 和 16, 丢弃率为 0.5。⑦ LMDA-Net^[23]: 使用 RA 样本预对齐, LMDA-Net 分类。⑧ Tensor-CSPNet^[22]: 使用 RA 样本预对齐, Tensor-CSPNet 分类。本文的 Tensor-CSPNet 使用了 9 个子频带 (4 ~ 8、8 ~ 12、12 ~ 16、16 ~ 20、20 ~ 24、24 ~ 28、28 ~ 32、32 ~ 36、36 ~ 40 Hz) 和 4 个子时间窗 (0 ~ 1、1 ~ 2、2 ~ 3、3 ~ 4 s)。

其中, CSP 提取最具鉴别性的 8 个维度的特征。RAVE 和 RSFDA 使用了相同的时间窗 (0 ~ 2 s, 1 ~ 3 s, 2 ~ 4 s, 0 ~ 3 s, 1 ~ 4 s, 0 ~ 4 s) 和频带 (8 ~ 13 Hz, 13 ~ 18 Hz, 18 ~ 26 Hz, 23 ~ 30 Hz, 8 ~ 30 Hz) 参数。所有深度学习方法使用 Adam 优化器, 初始学习率为 0.001, 并采用 CosineAnnealingLR 调度器动态调整学习率, 训练数据的批量大小为 32, 最大训练周期数为 300, 在连续 50 个训练周期内损失值没有明显改变时提前停止训练。

2.2.2 消融实验 该实验通过逐步去除 RSFDA 算法中的不同关键组件, 分析其对整体分类性能的贡献。共包括以下 7 种子方法: ① RSFDA-1: 去除 TF-Stacking 模块; ② RSFDA-2: 去除 RSF 模块;

③ RSFDA-3: 去除 MEFA 模块; ④ RSFDA-12: 同时去除 TF-Stacking 和 RSF 模块; ⑤ RSFDA-13: 同时去除 TF-Stacking 和 MEFA 模块; ⑥ RSFDA-23: 同时去除 RSF 和 MEFA 模块。⑦ RSFDA-123: 同时去除 TF-Stacking、RSF 和 MEFA 模块, 此方法等同于对比实验中的 TSM 方法。

2.3 统计分析

使用了文献 [29] 中描述的方法进行了统计分析。首先, 对于每个数据集中的每对分类方法组合, 采用基于单尾配对的 *t* 检验来检验 “一种分类方法不优于另一种分类方法” 的零假设, 并生成相应的 *P* 值。接着, 为了综合不同数据集的分类结果, 使用 Stouffer 方法对各数据集的 *P* 值进行荟萃分析。Stouffer 方法的具体步骤如下: 首先, 将每个 *P* 值转换为标准正态分数, 然后对这些标准正态分数求和, 最后根据求和结果计算出每对算法的整体 *P* 值。通过这种方法, 能够综合多个独立检验的结果, 从而得出更为可靠的统计结论。

2.4 对比实验结果

表 1 列出了各方法在三个数据集上的平均分类准确率 (每例被试的详细分类结果详见附件 1)。结果显示, RSFDA 方法在大多数情况下优于其他方法, 尤其是在数据集 1 和 3 上表现尤为突出。具体而言, 在数据集 1 上 RSFDA 的平均准确率为 72.10%, 对比排名第二的 MEKT 的 70.54%, 提高了 1.56%; 在数据集 3 上 RSFDA 的平均准确率为 84.95%, 对比排名第二的 TSM 的 82.34%, 提高了 2.61%。图 3 展示了所有方法之间的统计学差异。从整体表现来看, RSFDA 方法在全部数据上的平均分类准确率为 79.37%, 显著优于其他所有方法, 具体而言, 对比分类结果最好的基线方法 RAVE 的 76.57% 提高了 2.80% (*P* < 0.001), 对比深度学习方法 Tensor-CSPNet 的 76.46% 提高了 2.91% (*P* < 0.01)。

表 2 消融实验中各子方法的平均分类准确率 (%)

Tab.2 Average classification accuracy (%) of ablation study for each sub-method

方法	数据集1	数据集2	数据集3	全部数据
RSFDA	72.10 ± 10.97	83.24 ± 13.83	84.95 ± 12.56	79.37 ± 13.37
RSFDA-1	67.34 ± 9.30	77.97 ± 15.73	81.72 ± 13.34	75.00 ± 13.83
RSFDA-2	68.45 ± 12.94	82.18 ± 12.70	85.47 ± 10.14	77.82 ± 14.04
RSFDA-3	72.32 ± 11.74	84.10 ± 11.63	80.57 ± 14.40	78.18 ± 13.30
RSFDA-12	63.91 ± 11.86	74.52 ± 14.47	80.26 ± 13.76	72.25 ± 14.73
RSFDA-13	71.88 ± 9.18	79.12 ± 14.41	81.20 ± 13.42	76.93 ± 12.55
RSFDA-23	70.24 ± 12.98	82.38 ± 11.23	83.18 ± 11.02	77.80 ± 13.14
RSFDA-123	69.57 ± 10.98	78.54 ± 11.51	82.34 ± 11.70	76.26 ± 12.43

注：每个数据集上的最佳结果以粗体标记

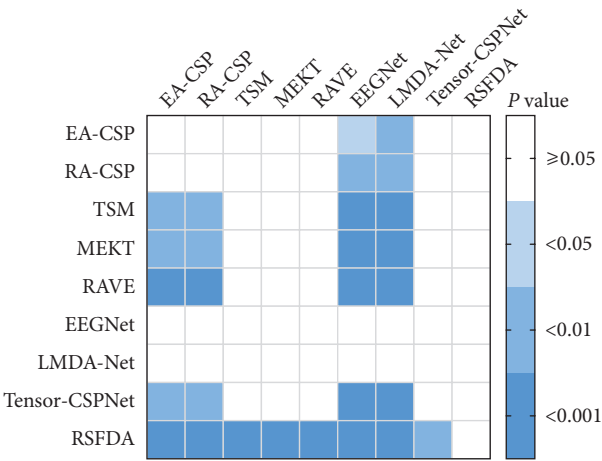


图 3 各对比方法分类结果的差异性统计分析 着色方框表示行中的分类方法优于列中的方法

Fig.3 Statistical analysis of differences in classification results across comparative methods the colored squares indicate that the method in the row outperforms the method in the column

2.5 消融实验结果

表 2 列出了 RSFDA 及其 7 种子方法在三个数据集上的平均分类准确率 (每例被试的详细分类结果详见附件 2)。图 4 展示了相应的各方法两两之间的统计学差异。从整体表现来看,完整版的 RSFDA 取得了最高的平均准确率 79.37%,对比 RSFDA-1、RSFDA-2、RSFDA-3、RSFDA-12、RSFDA-13、RSFDA-23 和 RSFDA-123 分别提高了 4.37% ($P < 0.001$)、1.55% ($P < 0.05$)、1.19% ($P < 0.05$)、7.12% ($P < 0.001$)、2.43% ($P < 0.001$)、1.57% ($P < 0.05$) 和 3.11% ($P < 0.001$)。

2.6 时间成本

表 3 中列出了所有分类方法在三个公开数据集上的平均训练时间。所有算法的评估都是在 一台配置为 Intel® Core™ i7-11800H @2.3GHz 处理器、GeForce RTX 3060 显卡和 32 GB 内存的计算机上完成的。结果显示,在各个数据集上 Tensor-CSPNet 的平均训练时间最长,超过了 25 min;

表 3 所有方法的平均训练时间 (s)

Tab.3 Average training time (s) of all method

方法	数据集1	数据集2	数据集3
EA-CSP	0.3 ± 0.1	0.2 ± 0.1	0.2 ± 0.1
RA-CSP	1.2 ± 0.2	1.1 ± 0.1	0.6 ± 0.1
TSM	2.4 ± 0.2	2.1 ± 0.1	1.1 ± 0.1
MEKT	2.7 ± 0.4	2.2 ± 0.1	1.1 ± 0.1
RAVE	112.3 ± 21.1	104.3 ± 18.9	32.8 ± 6.2
EEGNet	7.1 ± 4.4	8.1 ± 3.7	6.1 ± 2.9
LMDA-Net	11.7 ± 6.1	17.7 ± 9.7	18.3 ± 9.6
Tensor-CSPNet	1 584.7 ± 367.2	1 178.1 ± 268.8	1 265.5 ± 266.5
RSFDA	164.0 ± 17.8	143.1 ± 9.4	58.5 ± 10.7
RSFDA-1	35.4 ± 11.4	39.1 ± 10.1	17.0 ± 9.1
RSFDA-2	13.2 ± 0.7	9.6 ± 0.7	5.6 ± 0.2
RSFDA-3	162.8 ± 17.3	144.0 ± 10.1	57.7 ± 12.0
RSFDA-12	3.0 ± 0.3	2.5 ± 0.1	1.2 ± 0.1
RSFDA-13	36.7 ± 11.7	42.5 ± 9.6	16.0 ± 9.1
RSFDA-23	8.2 ± 1.4	6.0 ± 0.6	4.0 ± 0.2




图 4 消融实验中各子方法分类结果的差异性统计分析 着色方框表示行中的分类方法优于列中的方法

Fig.4 Statistical analysis of differences in classification results across sub-methods in ablation study the colored squares indicate that the method in the row outperforms the method in the column

RSFDA、RSFDA-3 和 RAVE 的平均训练时间在中等水平,为 1 ~ 3 min;其余算法的平均训练时间较短,在 1 min 以内。

3 讨论

从对比实验结果来看, RSFDA 方法在大多数数据集上的表现优于其他竞争方法, 其中包括了数据集 1、2 的左/右手 MI 分类任务和数据集 3 的右手/双脚 MI 分类任务, 展示了它在处理多样化任务时的优越性。尽管 RSFDA 在数据集 2 上略逊于 RAVE, 但这种差异极其微小, 且 RSFDA 在整体上的表现仍然优异, 显著超过了其他所有方法, 表明它在跨时间场景中拥有更稳定的表现。消融实验进一步验证了 RSFDA 方法各个组成模块的重要性。每个子模块的去除均导致分类性能的降低, 尤其是 TF-Stacking 模块的去除导致了最大的性能衰减, 这表明了该模块在 MI-EEG 跨时间分类中的关键作用。同时, 其他子模块的去除虽然性能下降较小, 但仍然显著影响着整体模型的表现, 说明 RSFDA 方法的各个组成部分相辅相成, 共同提升了模型的稳定性和准确率。这种模块化设计为未来的改进提供了灵活性, 可以在不影响整体结构的情况下对某一模块进一步优化。

对时间成本的分析表明, RSFDA 方法不仅在分类准确率上优于其他方法, 在计算效率方面也具有明显的优势。相比于最先进的深度学习方法 Tensor-CSPNet, RSFDA 在保证性能的同时, 显著降低了训练时间。这一效率优势使 RSFDA 在需要快速迭代和实时响应的实际应用场景中表现尤为突出, 例如在在线学习或实时数据处理任务中, 这种时间上的优势将带来显著的实用性。

尽管 RSFDA 方法在分类准确率和时间效率方面表现出色, 但本研究仍然存在一些局限性。首先, 虽然 RSFDA 在现有的数据集上表现良好, 但它在更具挑战性的迁移学习任务(例如跨场景和跨被试^[30])中的应用效果尚未充分验证。在这些场景中, 源域与目标域之间的分布差异更加复杂, 可能涉及到场景特征、主体特征以及设备差异等多个维度, 因此未来研究可以进一步扩展 RSFDA 在这些复杂场景中的应用, 并测试它在更广泛任务中的适应能力。其次, 尽管 RSFDA 在分类性能和计算效率之间取得了良好的平衡, 但在面对更大规模数据集时, 其时间成本仍然可能成为一个瓶颈。未来的研究可以对 RSFDA 的计算过程进一步优化, 例如探索 RSFDA 在分布式计算环境或并行计算框架下的应用, 以进一步提升它在大规模数据处理中的效率。最后, 虽然 RSFDA 已在多个跨时间 MI-EEG 解码任务中表现出色, 但与深度学习方法的结合仍

有潜力可挖。通过结合更强大的深度特征提取技术, 可能进一步提升 RSFDA 在高维数据和复杂特征提取任务中的表现。例如, 研究如何在保持高效计算的同时, 整合深度学习中的表征学习模块以提高模型的适应能力, 将是未来值得探讨的方向。

4 结论

本文提出了一种基于黎曼空间滤波与域适应的方法 RSFDA, 并通过对比实验、消融实验和时间成本分析验证了其有效性和高效性。实验结果表明, RSFDA 在多个公开数据集上均取得了优异的分类准确率, 在多数情况下优于现有的竞争方法。此外, 消融实验结果表明, RSFDA 的各模块协同工作显著提高了模型的性能, 验证了该方法模块设计的合理性。时间成本分析则表明, RSFDA 不仅在准确率上具有优势, 还将训练时间成本控制在较低水平, 计算效率显著优于最新的深度学习方法。尽管 RSFDA 在跨时间的 MI-EEG 分类任务中表现优越, 但它在更复杂的跨场景、跨被试等迁移学习场景中的适应性尚未得到充分验证。未来研究可以进一步探讨该方法在这些复杂场景中的应用, 并结合更强大的深度特征提取技术, 以提升其在大规模数据集和高维数据任务中的适应能力。

重要声明

利益冲突声明: 本文全体作者均声明不存在利益冲突。

作者贡献声明: 潘林聪、孙新维与曹愉培负责算法程序设计、数据分析、文章撰写和修订, 王坤、许敏鹏负责稿件的写作指导和修订, 明东完成了文章的审阅和校对。

本文附件见本刊网站的电子版本(biomedeng.cn)。

参考文献

- 1 Xu M P, He F, Jung P, *et al.* Current challenges for the practical application of electroencephalography-based brain-computer interfaces. *Engineering*, 2021, 7(12): 1710-1712.
- 2 Wen H, Zhong Y, Yao L, *et al.* Neural correlates of motor/tactile imagery and tactile sensation in a BCI paradigm: a high-density EEG source imaging study. *Cyborg Bionic Syst*, 2024, 5: 0118.
- 3 Flesher S N, Downey J E, Weiss J M, *et al.* A brain-computer interface that evokes tactile sensations improves robotic arm control. *Science*, 2021, 372(6544): 831-836.
- 4 Forenzo D, Zhu H, Shanahan J, *et al.* Continuous tracking using deep learning-based decoding for noninvasive brain-computer interface. *PNAS Nexus*, 2024, 3(4): 145.
- 5 王勇, 薛沐辉, 徐宝国, 等. 基于黎曼几何的自然动作运动参数脑电解码研究. *仪器仪表学报*, 2022, 43(7): 157-164.
- 6 Wang K, Tian F, Pan L, *et al.* Virtual reality game-based adaptive neurofeedback training for motor imagery// 12th Asian-Pacific

- Conference on Medical and Biological Engineering. Suzhou: Springer, 2024: 296-303.
- 7 邵谢宁, 张艺滢, 张栋, 等. 融合多感官刺激的虚拟现实——脑机接口手功能增强康复系统. 生物医学工程学杂志, 2024, 41(4): 656-663.
- 8 谢士遥, 汤佳贝, 蔡雨, 等. 脑电BCI系统的软硬件开发平台发展现状. 电子测量与仪器学报, 2022, 36(6): 1-12.
- 9 Jaiswal M K. Toward a high-resolution neuroimaging biomarker for mild traumatic brain injury: from bench to bedside. *Front Neurol*, 2015, 6: 148.
- 10 Pan L, Wang K, Xu L, *et al.* Riemannian geometric and ensemble learning for decoding cross-session motor imagery electroencephalography signals. *J Neural Eng*, 2023, 20(6): 066011.
- 11 潘林聪, 王坤, 许敏鹏, 等. 面向运动意图解码的共空间模式及其扩展算法研究综述. 中国生物医学工程学报, 2022, 41(5): 577-588.
- 12 Wu D, Jiang X, Peng R. Transfer learning for motor imagery based brain-computer interfaces: a tutorial. *Neural Netw*, 2022, 153: 235-253.
- 13 Wu D R, Xu Y F, Lu B L. Transfer learning for EEG-based brain-computer interfaces: a review of progress made since 2016. *IEEE T Cogn Dev Syst*, 2022, 14(1): 4-19.
- 14 胡莹, 刘燕, 程晨晨, 等. 基于自适应时频共空间模式结合卷积神经网络的多任务运动想象脑电分类. 生物医学工程学杂志, 2022, 39(6): 1065-1073, 1081.
- 15 李红利, 刘浩雨, 陈虹宇, 等. 基于时间序列数据增强的运动想象脑电多尺度特征提取分类. 生物医学工程学杂志, 2023, 40(3): 418-425.
- 16 Kumar S, Yger F, Lotte F. Towards adaptive classification using Riemannian geometry approaches in brain-computer interfaces// 2019 7th International Winter Conference on Brain-Computer Interface (BCI). Gangwon: IEEE, 2019: 1-6.
- 17 Barachant A, Bonnet S, Congedo M, *et al.* Multiclass brain-computer interface classification by Riemannian geometry. *IEEE Trans Biomed Eng*, 2012, 59(4): 920-928.
- 18 Zanini P, Congedo M, Jutten C, *et al.* Transfer learning: a Riemannian geometry framework with applications to brain-computer interfaces. *IEEE Trans Biomed Eng*, 2018, 65(5): 1107-1116.
- 19 Lahav A, Talmon R. Procrustes analysis on the manifold of SPSD matrices for data sets alignment. *IEEE T Signal Process*, 2023, 71: 1907-1921.
- 20 Zhang W, Wu D. Manifold embedded knowledge transfer for brain-computer interfaces. *IEEE Trans Neural Syst Rehabil Eng*, 2020, 28(5): 1117-1127.
- 21 Lawhern V J, Solon A J, Waytowich N R, *et al.* EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces. *J Neural Eng*, 2018, 15(5): 056013.
- 22 Ju C, Guan C. Tensor-CSPNet: a novel geometric deep learning framework for motor imagery classification. *IEEE Trans Neural Netw Learn Syst*, 2023, 34(12): 10955-10969.
- 23 Miao Z, Zhao M, Zhang X, *et al.* LMDA-Net: a lightweight multi-dimensional attention network for general EEG-based brain-computer interfaces and interpretability. *Neuroimage*, 2023, 276: 120209.
- 24 Pan L, Wang K, Sun X, *et al.* Riemannian geometry-based spatial filtering (RSF) method for motor imagery EEG classification// Proceedings of the 2024 9th International Conference on Biomedical Signal and Image Processing. Suzhou: Association for Computing Machinery, 2024: 48-54.
- 25 Park S H, Lee D, Lee S G. Filter bank regularized common spatial pattern ensemble for small sample motor imagery classification. *IEEE Trans Neural Syst Rehabil Eng*, 2018, 26(2): 498-505.
- 26 Tangermann M, Muller K R, Aertsen A, *et al.* Review of the BCI competition IV. *Front Neurosci*, 2012, 6: 55.
- 27 Faller J, Vidaurre C, Solis-Escalante T, *et al.* Autocalibration and recurrent adaptation: towards a plug and play online ERD-BCI. *IEEE Trans Neural Syst Rehabil Eng*, 2012, 20(3): 313-319.
- 28 He H, Wu D. Transfer learning for brain-computer interfaces: a euclidean space data alignment approach. *IEEE Trans Biomed Eng*, 2020, 67(2): 399-410.
- 29 Jayaram V, Barachant A. MOABB: trustworthy algorithm benchmarking for BCIs. *J Neural Eng*, 2018, 15(6): 066011.
- 30 Xu L, Xu M, Ma Z, *et al.* Enhancing transfer performance across datasets for brain-computer interfaces using a combination of alignment strategies and adaptive batch normalization. *J Neural Eng*, 2021, 18(4): 0460e5.

收稿日期: 2024-11-18 修回日期: 2025-03-19

本文编辑: 李蓓兰