

# 基于黎曼空间滤波与域适应的跨时间运动想象-脑电解码研究

潘林聪, 孙新维, 王坤, 曹愉培, 许敏鹏\*, 明东

天津大学医学工程与转化医学研究院, 天津, 300072; 天津大学精密仪器与光电子工程学院, 天津, 300072;

脑机交互与人机共融海河实验室, 天津, 300392

## 摘要

本研究针对运动想象脑电 (MI-EEG) 信号在跨时间场景下的非平稳性和低信噪比问题, 提出了一种新型分类方法 **RSFDA** (Riemannian Spatial Filtering and Domain Adaptation)。该方法通过黎曼空间滤波 (**RSF**) 降低数据维度并增强特征可分性, 结合黎曼对齐 (**RA**) 消除电极位移等变异, 利用流形嵌入式特征对齐 (**MEFA**) 解决源域与目标域分布差异, 并引入时频特征融合集成学习 (**TF-Stacking**) 提升模型鲁棒性。在三个公开数据集 (BNCI2014-001、BNCI2015-001和Pan2023) 上进行了验证, RSFDA实现了**79.37%** 的平均分类准确率, 显著优于8种基线方法 (较最优深度学习模型Tensor-CSPNet提升**2.91%**,  $P < 0.01$ ), 同时训练时间仅需**3分钟** (对比Tensor-CSPNet, 效率提升**88%**)。该方法为跨时间MI-BCI系统提供了高精度、低计算成本的解决方案。

## 方法

RSFDA采用多级处理框架 (图1):

- 黎曼空间滤波 (RSF)** 首先计算EEG协方差矩阵, 通过优化投影矩阵最大化两类样本的黎曼距离, 实现数据降维与关键特征增强。
- 黎曼对齐 (RA)** 以黎曼几何均值为参考对齐样本协方差矩阵, 消除跨时段电极位移等引起的脑电信号变异。
- 切空间映射 (TSM)** 将样本映射至黎曼切空间生成几何特征向量。
- 流形嵌入式特征对齐 (MEFA)** 通过域适应对齐源域和目标域特征分布。

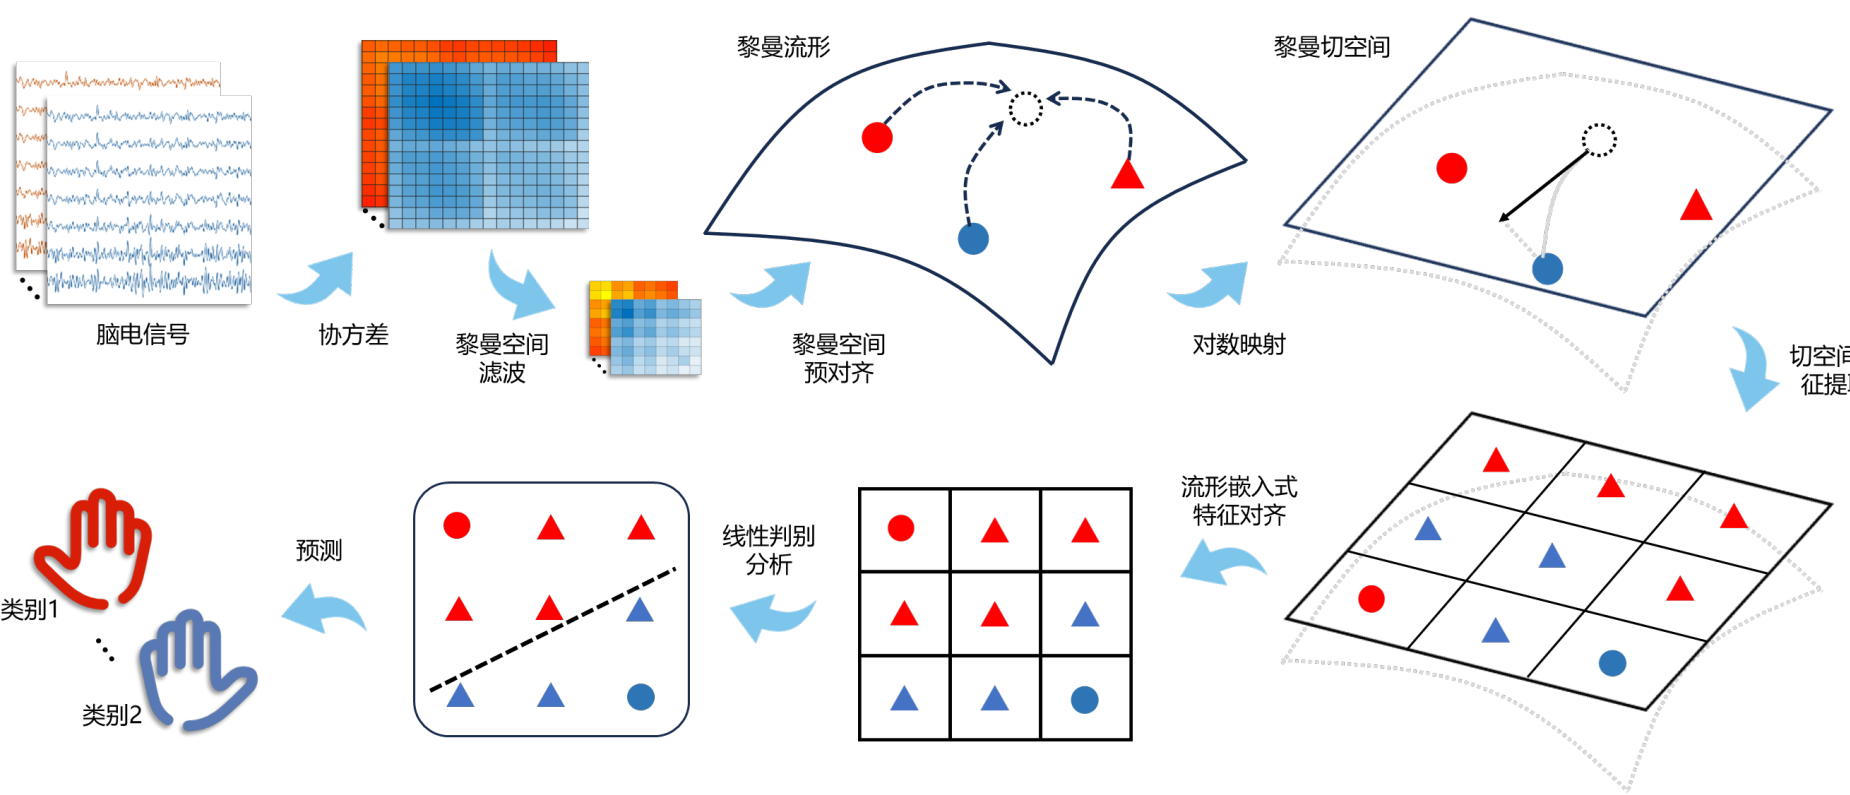


图1 RSFDA基础模型计算流程

- 时频特征融合集成学习 (TF-Stacking)** 融合多时频窗基模型, 增强时频特征表达能力, 最终训练元分类器输出结果 (图2)。

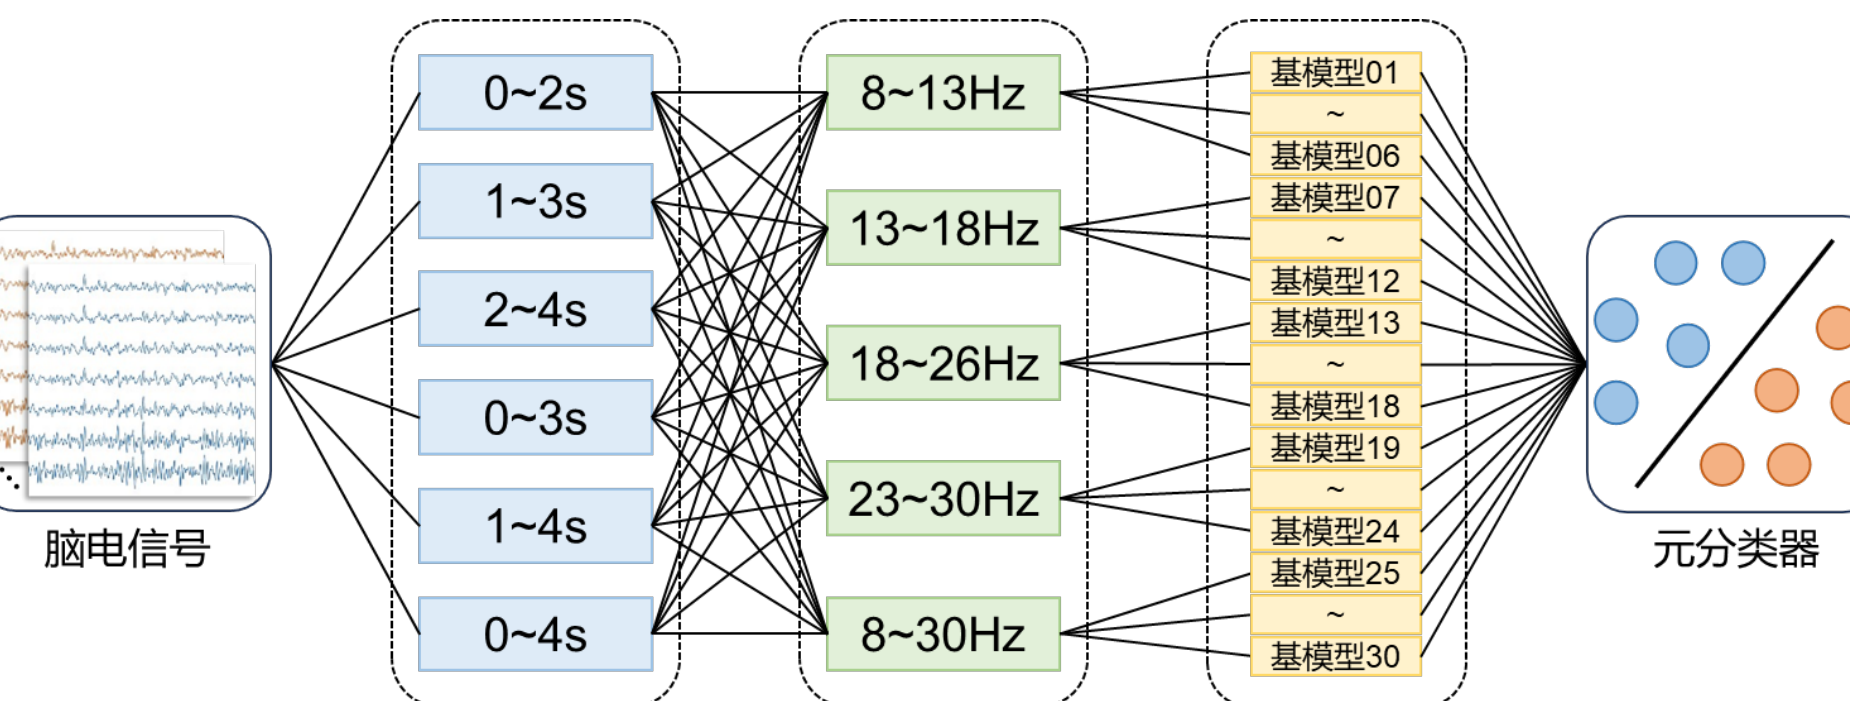


图2 TF-Stacking元分类器计算流程

公开源代码: <https://github.com/PLC-TJU/RSFDA>

## 数据

本研究使用了三个公开数据集 (表1)。每名被试包含两个不同时间段的脑电数据, 每个时间段的样本数相同。每名受试者包含两个类别的样本, 每个类别的样本数相同。所有数据经 8~30 Hz带通滤波预处理。

表1 数据集详细信息

数据集	类别	样本数	通道数	时长/s	被试数
Pan2023	左/右手	240	28	4	14
BNCI2014-001	左/右手	288	22	4	9
BNCI2015-001	右手/脚	400	13	4	12
总计					35

## 实验

本研究采用对比实验与消融实验双验证框架:

- 对比实验:** 选取8种代表性方法, 涵盖传统机器学习方法 (EA-CSP、RA-CSP、TSM、MEKT、RAVE) 与深度学习模型 (EEGNet、LMDA-Net、Tensor-CSPNet)。
- 消融实验:** 系统移除RSFDA的三大核心模块 (TF-Stacking、RSF、MEFA), 生成7种子方法 (表2)。
- ① 数据划分: 每名被试时段1全样本作为源域, 时段2前20%样本作为目标域训练集, 后80%样本作为测试集。
- ② 统计检验: 基于Stouffer荟萃分析整合多数据集, 验证总体显著性 ( $P < 0.05$ )。

表2 消融实验各子分类方法成分

算法	TF-Stacking	RSF	MEFA	基础模块
RSFDA	√	√	√	√
RSFDA-1		√	√	√
RSFDA-2	√		√	√
RSFDA-3	√	√		√
RSFDA-12			√	√
RSFDA-13		√		√
RSFDA-23	√			√
RSFDA-123				√

## 创新点

本研究的核心创新包括以下几点:

- 新型空间滤波机制:** 首次将黎曼空间滤波与域适应结合, 通过RSF在降维同时最大化类间可分性, 突破传统欧氏空间滤波局限。
- 特征对齐方法革新:** 改进MEKT方法提出MEFA, 引入标签约束增强跨时段特征分布一致性, 解决现有无监督迁移的泛化瓶颈。
- 动态时频融合架构:** 设计TF-Stacking级联多时频窗基模型, 克服单一时频特征表达能力不足问题, 提升系统鲁棒性。

## 结果与讨论

主要发现:

- 对比试验** (图3a、b): RSFDA的平均准确率达79.37%, 较最先进的深度学习方法Tensor-CSPNet (76.46%) 提升2.91% ( $P < 0.01$ )。
- 消融实验** (图3c、d): 移除TF-Stacking导致最大性能下降 (-4.37%,  $P < 0.001$ ), 验证其关键作用; RSF与MEFA模块的移除分别降低性能1.55%和1.19% ( $P < 0.05$ ), 表明多模块协同必要性。
- 时间效率** (表3): RSFDA平均训练时间约3分钟, 显著低于Tensor-CSPNet (约25分钟), 计算效率提升88%。

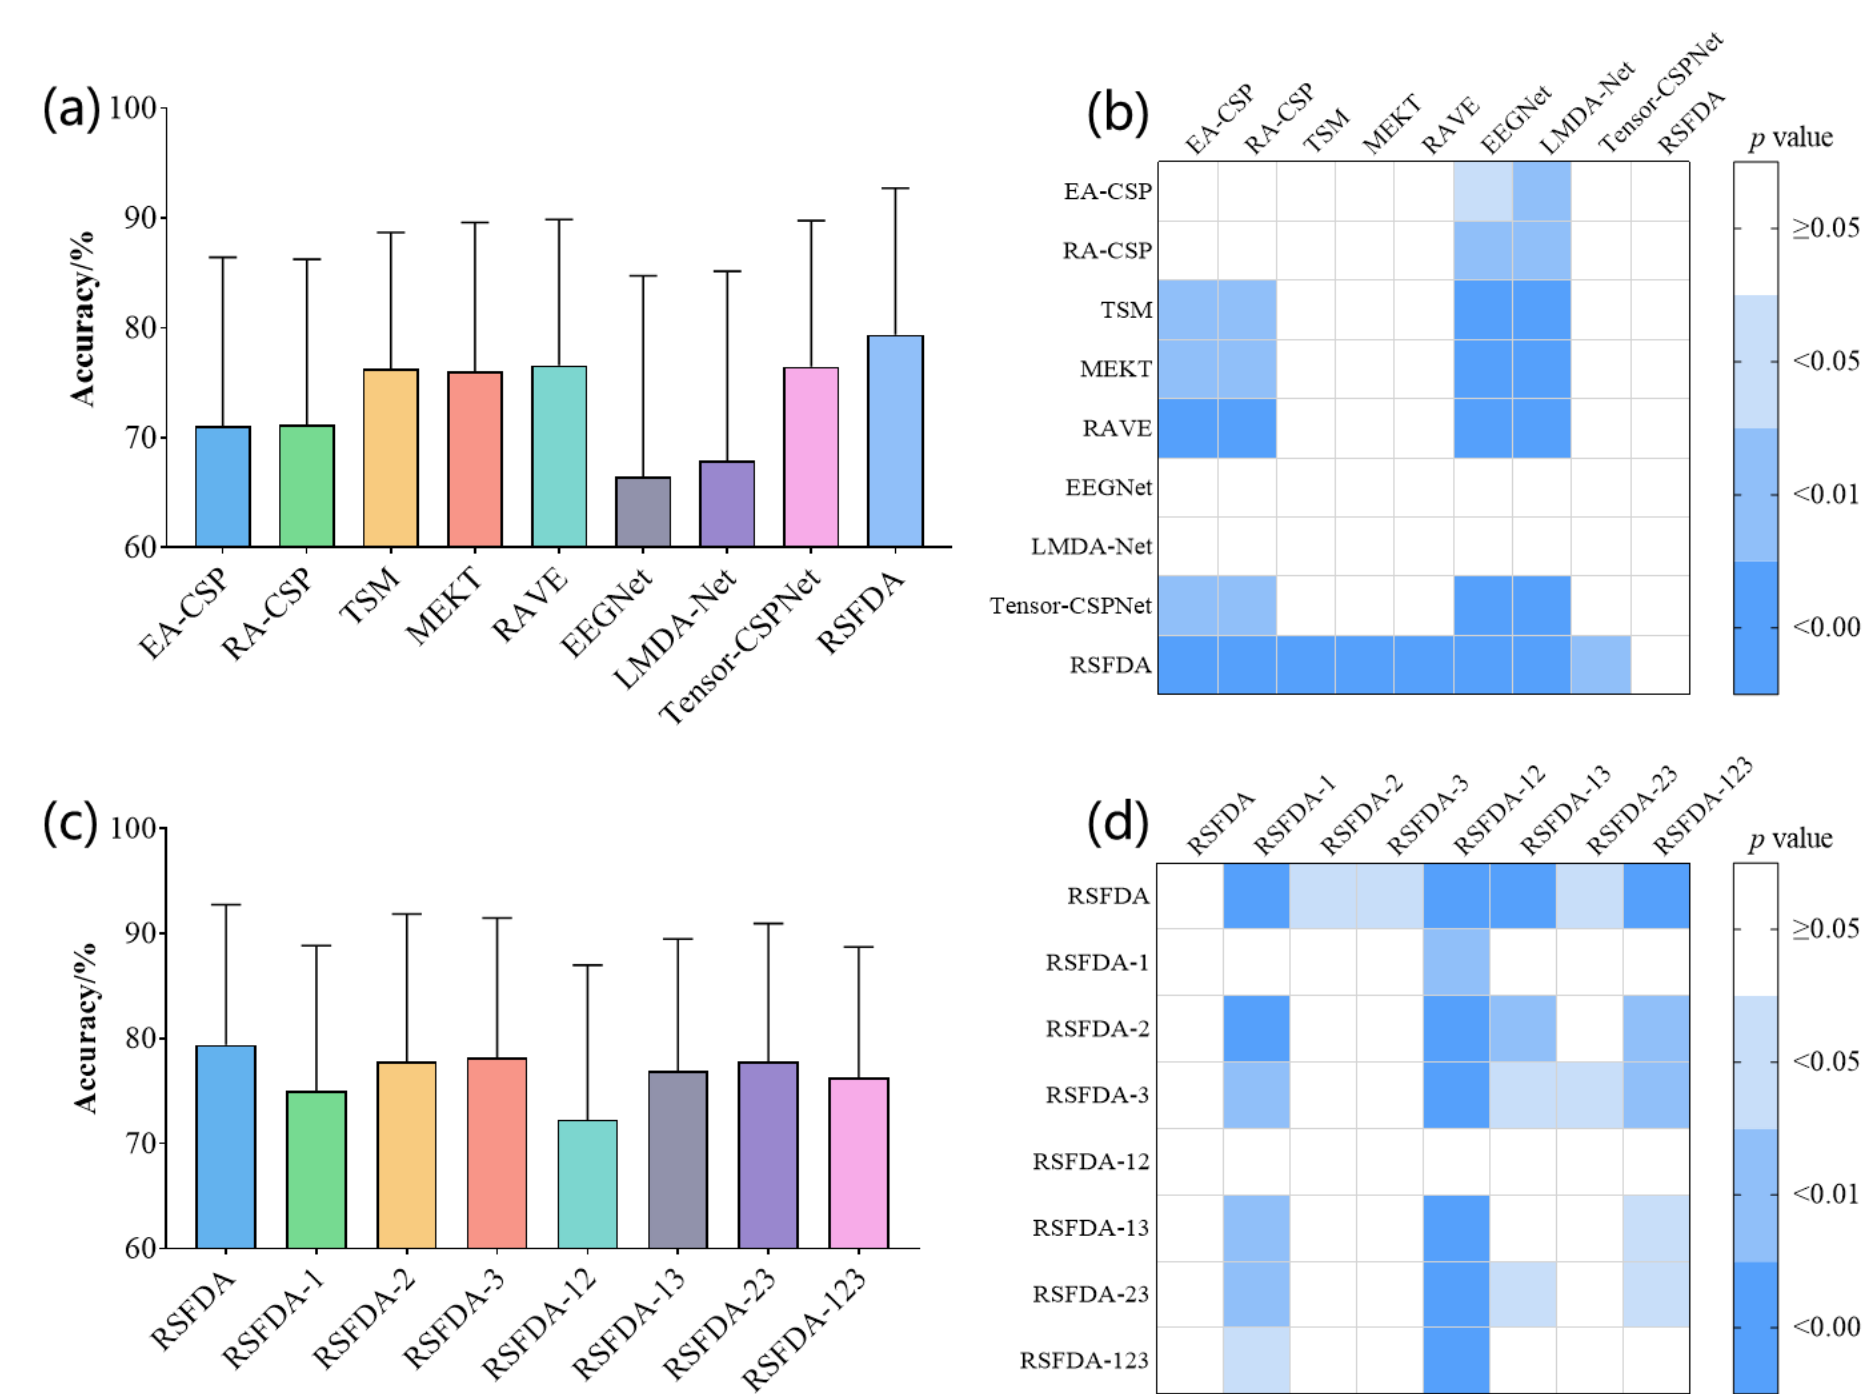


图3 不同方法的平均分类准确率和差异性统计分析

(图a为对比实验各方法的分类结果; 图b为对比实验各方法分类结果的差异性; 图c为消融实验各方法的分类结果; 图d为消融实验各方法分类结果的差异性。图b和图c中着色方块表示行中的分类方法显著优于列中的分类方法)

表3 训练时间成本 (秒)

方法	Pan2023	BNCI2014-001	BNCI2015-001
EA-CSP	0.3±0.1	0.2±0.1	0.2±0.1
RA-CSP	1.2±0.2	1.1±0.1	0.6±0.1
TSM	2.4±0.2	2.1±0.1	1.1±0.1
MEKT	2.7±0.4	2.2±0.1	1.1±0.1
RAVE	112.3±21.1	104.3±18.9	32.8±6.2
EEGNet	7.1±4.4	8.1±3.7	6.1±2.9
LMDA-Net	11.7±6.1	17.7±9.7	18.3±9.6
Tensor-CSPNet	<b>1584.7±367.2</b>	1178.1±268.8	1265.5±266.5
RSFDA	<b>164.0±17.8</b>	143.1±9.4	58.5±10.7

讨论与展望:

核心优势

RSFDA通过多模块协同解决了跨时间MI-EEG解码的两大挑战:

- 分布差异问题: RA与MEFA的级联设计降低时段间分布偏移。
- 特征表达能力局限: RSF与TF-Stacking分别从空间和时频维度增强判别性特征提取。

局限性

- 尚未验证跨被试/跨场景迁移性能。
- 大规模数据处理的扩展性需进一步优化。

未来方向

- 拓展至跨被试、跨场景迁移任务, 验证复杂场景适应性。
- 开发分布式计算框架, 优化大规模数据处理效率。

## 结论

RSFDA通过黎曼空间滤波→分布对齐→时频集成的创新链路, 显著提升跨时间MI-EEG解码性能。该方法为MI-BCI实用化提供了兼具精度与效率的解决方案, 未来将进一步探索其在复杂迁移场景中的应用。